Харитон **Пицик**

Junior ML Engineer · ML Intern

Саратов, Россия

25.04.2005 pitsikhariton@yandex.ru haritonn @hariton_p



О себе

Студент 4 курса, увлекаюсь машинным обучением, особенно NLP, LLM и информационным поиском. Разрабатываю пайплайны на Python и PyTorch, оцениваю качество моделей и преподаю ML в студенческом сообществе. Рассматриваю работу и стажировки в ML engineering.

Навыки

Языки программирования	Python, SQL, Rust, Go
ML / DL	PyTorch, Scikit-learn, XGBoost, CatBoost, NumPy, Pandas, Polars
NLP / LLM	Transformers, RAG, Qdrant, FAISS, Ollama, LangChain
Оценка и эксперименты	Jupyter notebook, ranx, Optuna, ClearML, MLFlow, LangSmith
Разработка	Git & GitHub, Docker, Linux, FastAPI, PostgreSQL, Streamlit
Тестирование и CI	pytest, Модульные и интеграционные тесты, GitHub Actions
Базовые знания	Линейная алгебра, Матанализ, Теория вероятностей и статистика, Обучение с учителем и без учителя, NLP
Языки общения	Русский (родной), Английский (B2)

Практический опыт

Распознавание речи и диаризация спикеров

haritonn/asr_practice

Проект производственной практики.

- Разработал пайплайн транскрибации русскоязычных диалогов: Faster-Whisper, Silero VAD и pyannote; связал реплики со спикерами.
- Добавил распознавание терминов каталога через NeMo CTC context graph без дообучения ASR; оценил WER, CER, DER и F1 распознавания терминов.

Проекты

Локальная RAG-система по научным статьям

haritonn/qasper_rag_system

- Разработал вопросно-ответную систему на QASPER: индексация абзацев, BGE/BM42-эмбеддинги через FastEmbed, гибридный поиск Qdrant с RRF, cross-encoder reranking и локальная генерация через Ollama/Qwen3 8B.
- Оценил поиск внутри статьи на 888 из 1 005 validation-вопросов: reranking повысил MRR@10 с 0,4313 до 0,5221 и Recall@10 с 0,6932 до 0,7493.
- Разделил компоненты поиска и генерации интерфейсами; добавил метаданные источников в CLI, модульные и интеграционные тесты, CI в GitHub Actions и фиксацию зависимостей через uv.

Биомедицинская поисковая система

haritonn/fitness_se

- Разработал поиск по 23 283 статьям Europe PMC о тренировках, восстановлении и спортивном питании: взвешенный BM25, семантический поиск MedCPT/FAISS и гибридный поиск с RRF.
- Оценил качество на 150 запросах и 3 000 оценках релевантности; BM25 достиг тестового nDCG@10 = 0,5019. Добавил предварительную разметку через Ollama/Qwen3 8B, Streamlit-интерфейс и CI в GitHub Actions.

Генерация описаний изображений

haritonn/caption_gen

- Разработал генерацию описаний изображений на Flickr8k в PyTorch: ResNet-50 и LSTM-декодер с soft-attention; применил scheduled sampling, label smoothing и early stopping.
- Обеспечил воспроизводимость через фиксированные разбиения, чекпоинты и опциональный ClearML; получил BLEU 0,1655 и METEOR 0,3774 на validation-выборке.

ResNet с канальным механизмом внимания

haritonn/resnet_attention

- Реализовал с нуля ResNet-50 и вариант с канальным attention на PyTorch; сравнил сходимость, accuracy и F1.
- Добавил пайплайны обучения и инференса, early stopping, визуализацию внимания и трекинг экспериментов в ClearML.

cargo-smi — мониторинг NVIDIA GPU

haritonn/cargo-smi

- Разработал Rust TUI для мониторинга GPU и системы на NVML, Ratatui, Crossterm и Sysinfo: VRAM, загрузка, температура, CPU/RAM и процессы.
- Реализовал переключение между GPU, настраиваемое обновление и графики истории загрузки.

Курсовые работы

Дипломная работа: GraphRAG для вопросно-ответных систем на основе документов и графа знаний

WIP

3 курс: Восстановление иерархии событий методом кластеризации текстовых эмбеддингов

haritonn/coursework3

Исследовал влияние геометрии эмбеддингов на кластеризацию новостных событий: 2 604 эксперимента HDBSCAN, 3 семейства эмбеддингов, 93 пространства признаков и 28 значений параметра. UMAP повысил лучший F1 для каждого семейства; Jina Embeddings v5 + UMAP(10) дали F1 = 0,837.

2 курс: генеративное компьютерное зрение

haritonn/coursework2

Сравнил диффузионные модели, GAN и подходы на основе мультимодальных моделей (LMM) для виртуальной примерки; оценил визуальное качество и время инференса на собственном датасете.

Образование

Саратовский государственный университет

Саратов, Россия

Бакалавриат | Фундаментальная информатика и информационные технологии

Сентябрь 2023 — июнь 2027

Преподавание и сообщество

- Преподаю машинное обучение в Development Students Clubs (DSC).
- Записи лекций: NumPy, Pandas плейлист клуба ML.